大數據分析 HW1

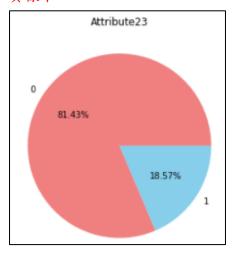
M11015Q06 顏齊

數據理解

1. 首先將有缺失值的資料全部捨棄,保留無缺失資料,利用無缺失資料進行分析,由下圖我們可以發現明天是否下兩(Attribute23)與當天陽光出現時數 (Attribute7)最有關係,所以在撰寫程式時我們將以 Attribute7 為重點分析特徵。

```
df_data = df_data.dropna()
  df_data.corr()['Attribute23']
Attribute2
             -0.008408
Attribute3
            0.080067
Attribute4 -0.134566
Attribute5
             0.256521
Attribute6
            -0.122929
Attribute7
            -0.431394
Attribute8 0.078966
             0.229648
Attribute9
Attribute10 0.039686
Attribute11 0.046196
Attribute12 0.063670
             0.084580
Attribute13
Attribute14
             0.256332
Attribute15 0.413247
Attribute16 -0.236084
           -0.215623
0.308651
Attribute17
Attribute18
Attribute19
            0.364257
Attribute20 -0.017706
            -0.165463
Attribute21
            0.306277
Attribute22
Attribute23
            1.000000
year
             -0.022761
             0.011603
```

2. 根據 Attribute23 圓餅圖,可以發現 train_data 有數據不平衡的問題,所以在填補缺失值及訓練模型時,我們將調整 scale_pos_weight 參數平衡正負樣本。



程式架構

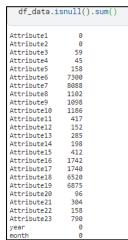
1. 首先將訓練集和測試集合併(同步處理),並將類別型資料(風向、明日是否下雨、今日是否下雨)轉換成數字型態。

```
train_data = pd.read_csv("../input/bigdata-hw1/train.csv")#(17093, 23)
test_data = pd.read_csv("../input/bigdata-hw1/test.csv")#(790, 22)
location = dict(N=1, NNE=2, NE=3, ENE=4, E=5, ESE=6, SE=7, SSE=8, S=9, SSW=10, SW=11, WSW=12, W=13, WNW=14, NW=15, NNW=16)
df_data = train_data.append( test_data )
df_data['Attribute22'] = df_data['Attribute22'].map(dict(Yes=1, No=0))##Attribute22 string換成num
df_data['Attribute3'] = df_data['Attribute23'].map(dict(Yes=1, No=0))##Attribute23 string換成num
df_data['Attribute8'] = df_data['Attribute8'].map(location)##string方位換成NUM
df_data['Attribute10'] = df_data['Attribute10'].map(location)##string方位換成NUM
df_data['Attribute11'] = df_data['Attribute11'].map(location)##string方位換成NUM
```

2. 透過 Attributel 年月日期資料新增 Month、Year 特徵

```
df_data['Attribute1'] = df_data['Attribute1'].apply(pd.to_datetime)#將 年月日->月*30+日 df_data['year'] = df_data['Attribute1'].dt.year df_data['month'] = df_data['Attribute1'].dt.month
```

3. 觀察缺失值,可以發現 Attribute6, 7, 18, 19 缺失值最多,缺失值占比過大的特徵將無法填補,否則會失去原始資料的真實性,所以我們將不使用 Attribute6, 18, 19 特徵訓練模型。



4. 此外,因 Attribute7 與目標值關係密切,我們無法在不考慮 Attribute7 的情況下預測目標值,所以我先用 dp_data 資料集訓練 XGBRegressor,再對 Attribute7 進行預測填補。

(Note: dp_data 為訓練集資料除去 Attribute3, 4, 5, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 20, 21, 22 缺失值的數據)

```
dp_data = df_data[:len(train_data)]
#train_data = train_data.dropna(axis=0, how='any', thresh=None, subset=None, inplace=False)
dp_data = dp_data[(dp_data['Attribute3'].notna()) & (dp_data['Attribute3'].notna()) & (dp_data['Attribute3'].no
```

5. 將步驟 1 合併的資料拆分數據集、測試集,再對訓練集缺失的 Attribute7 進行填補。

6. 最後,使用數據集訓練 XGBClassifier 並預測測試集目標值。

7. 交叉驗證

```
from sklearn.model_selection import train_test_split, cross_val_score, cross_val_predict, cross_validate, GridSearchCV
from sklearn.metrics import accuracy_score, balanced_accuracy_score
dict_models = {
    'XGBClassifier': XGBClassifier(learning_rate=0.1, scale_pos_weight = 5, n_estimators = 28),
}

for name, model in dict_models.items():
    cv_predict = cross_val_predict(model,train_data[predict_final],train_data["Attribute23"], cv=10)
    accuracy = round(accuracy_score(train_data["Attribute23"], cv_predict), 3)
    balanced_accuracy = round(balanced_accuracy_score(train_data["Attribute23"], cv_predict), 3)
    print(f'model:{name}, accuracy:{accuracy}, balanced_accuracy:{balanced_accuracy}')
```

model:XGBClassifier, accuracy:0.798, balanced_accuracy:0.796